

Proyecto EDA con Python

Análisis exploratorio de campañas de marketing bancario

Este informe resume el análisis exploratorio de datos realizado con Python sobre los archivos bank-additional.csv y customer-details.xlsx. El objetivo es estudiar los factores asociados a la suscripción de un depósito bancario tras campañas de marketing directo.

1. Resumen ejecutivo

El análisis parte de 43,000 registros de campañas bancarias y 43,170 registros de clientes procedentes de tres hojas de Excel. Tras limpiar y unir las fuentes por el identificador del cliente, se mantiene una base principal de 43,000 observaciones para el EDA.

La tasa general de conversión es del 11.27%. La variable con mayor relación directa con la contratación es la duración de la llamada: los clientes que contrataron tuvieron llamadas medias de 551.62 segundos, frente a 220.43 segundos en los que no contrataron.

También destacan el resultado de campañas anteriores, el método de contacto y algunos segmentos por profesión y edad. En cambio, ingresos y visitas web muestran diferencias reducidas entre contratantes y no contratantes.

2. Metodología y preparación de datos

El trabajo se ha desarrollado en Python mediante Pandas, NumPy y Matplotlib. Primero se revisó la estructura de ambos archivos, después se aplicaron transformaciones de limpieza y finalmente se realizaron análisis descriptivos, agrupaciones y visualizaciones.

Principales transformaciones aplicadas:

- Eliminación de columnas índice innecesarias como Unnamed: 0.
- Unión de las tres hojas del Excel en un solo dataframe, añadiendo customer_year.
- Conversión de decimales almacenados como texto con coma decimal.
- Conversión de fechas españolas a formato datetime.
- Normalización de categorías y tratamiento de ausentes como unknown en variables cualitativas.
- Creación de variables derivadas: subscribed, call_duration_min, previously_contacted, age_group, income_group y total_children.
- Unión de datos por id_ para obtener una tabla final combinada.

3. Dimensión de los datasets

Dataset	Registros	Comentario
bank-additional.csv	43000	Campañas y resultado de contratación
customer-details.xlsx	43170	Información demográfica y web de clientes
Base unida	43000	Base final tras cruce por id_

El cruce fue completo para los 43,000 registros de campañas. Además, existen 170 clientes del Excel que no aparecen en el CSV de campañas, por lo que no se incluyen en la base principal de análisis.

4. Calidad de datos y valores ausentes

La revisión de valores ausentes permitió detectar campos con un volumen relevante de datos faltantes. En lugar de eliminar registros masivamente, se optó por una limpieza conservadora para no reducir el tamaño de muestra.

column	missing_values	missing_pct
euribor3m	9256	21.53
default	8981	20.89
age	5120	11.91
education	1807	4.20
loan	1026	2.39
housing	1026	2.39
cons.price.idx	471	1.10
job	345	0.80
date	248	0.58
marital	85	0.20

Las variables categóricas con ausencias se completaron con la categoría unknown. En variables numéricas se conservaron los nulos para evitar introducir valores artificiales en el análisis descriptivo.


5. Análisis descriptivo

variable	count	mean	std	min	median	max
age	37,880.00	39.98	10.44	17.00	38.00	98.00
duration	43,000.00	257.74	258.67	0.00	179.00	4,918.00
campaign	43,000.00	2.57	2.77	1.00	2.00	56.00
previous	43,000.00	0.17	0.50	0.00	0.00	7.00
Income	43,000.00	93,241.20	50,498.32	5,841.00	93,050.50	180,802.00
NumWebVisitsMonth	43,000.00	16.59	9.24	1.00	17.00	32.00
total_children	43,000.00	2.00	1.15	0.00	2.00	4.00

La edad media es de 39.98 años y la mediana de 38.00 años. El ingreso medio de los clientes cruzados se sitúa en 93,241.20, con una mediana de 93,050.50.


6. Variable objetivo

La variable objetivo es y, que indica si el cliente contrató o no el depósito. La base presenta una tasa de conversión del 11.27%, lo que implica que la mayoría de contactos no terminan en contratación.




7. Resultados por segmentos

La conversión varía de forma relevante según el segmento profesional. Estudiantes y jubilados son los grupos con mejor comportamiento relativo, mientras que servicios y blue-collar presentan tasas inferiores.



job	count	conversion_pct
student	903	31.34
retired	1790	25.20
unemployed	1063	14.39
admin.	10873	13.01
unknown	345	11.30
management	3050	11.21
technician	7026	10.85
self-employed	1489	10.81


El resultado de campañas anteriores es uno de los factores más claros: cuando la campaña anterior fue exitosa, la probabilidad de contratación es mucho más alta.



poutcome	count	conversion_pct
success	1436	65.32
failure	4461	14.23
nonexistent	37103	8.82


8. Edad, ingresos y método de contacto

Por edad se observa una conversión especialmente elevada en el grupo de 60 años o más. También existe mejor conversión en los clientes más jóvenes que en los tramos centrales de edad.



age_group	count	conversion_pct
<=29	5266	16.12
30-39	15609	10.12
40-49	9650	8.00
50-59	6258	10.12
60+	1097	39.38


La segmentación por ingresos no muestra grandes diferencias entre cuartiles, por lo que el ingreso no parece ser el factor más determinante en este conjunto de datos.



income_group	count	conversion_pct
bajo	10750	11.29
medio-bajo	10750	11.51
medio-alto	10750	11.42
alto	10750	10.84


9. Duración de llamada y correlaciones

La duración de la llamada muestra una diferencia clara entre clientes que contratan y clientes que no contratan. Este resultado debe interpretarse con cautela, porque la duración se conoce al final de la llamada, pero resulta útil para entender la dinámica comercial.



y	count	mean	median	std
no	38156	220.43	163.00	207.12
yes	4844	551.62	449.00	398.40

El mapa de correlaciones confirma que duration, nr.employed, pdays, euribor3m, emp.var.rate y previous son las variables numéricas más relacionadas con la suscripción. La correlación no implica causalidad, pero permite identificar patrones relevantes para orientar análisis posteriores.



variable	correlacion_con_subscribed
duration	0.40
nr.employed	-0.36
pdays	-0.33
euribor3m	-0.31
emp.var.rate	-0.30
previous	0.23
cons.price.idx	-0.14
campaign	-0.07

10. Conclusiones finales

1. La tasa global de conversión es reducida (11.27%), por lo que la campaña presenta un fuerte predominio de respuestas negativas.
2. La duración de la llamada es el indicador más asociado a la contratación, con diferencias muy claras entre clientes que contratan y no contratan.
3. El resultado positivo de campañas anteriores identifica clientes con mayor predisposición a contratar.
4. El contacto celular obtiene mejores resultados que telephone, por lo que conviene revisar el canal de contacto usado en la campaña.
5. Las variables de ingresos y visitas web tienen menor capacidad descriptiva en este conjunto de datos que las variables propias de la campaña.
6. La estrategia recomendada es priorizar calidad de contacto y segmentación por historial, profesión y edad antes que aumentar de forma indiscriminada la frecuencia de llamadas.